DLHLP HW4-1 Report

組長 Githud ID: openopentw
組員 (姓名 + 學號): 鄭淵仁 R08922067

Part 1

1 請將 training 的 loss curve 跟 test accuracy 截圖放在下面，並簡單交待一下你的 training 過程

1.(a) loss curve

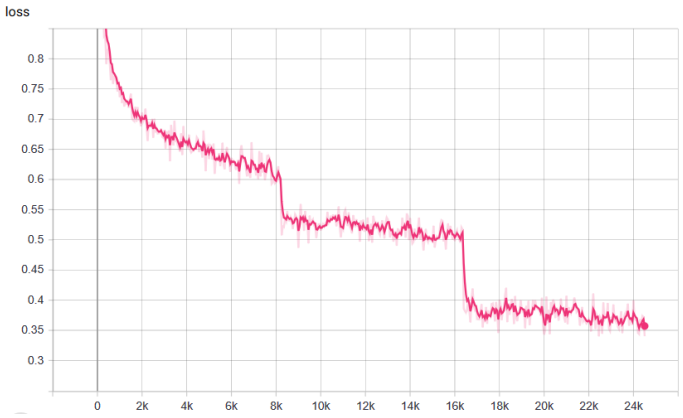

1.(b) test accuracy

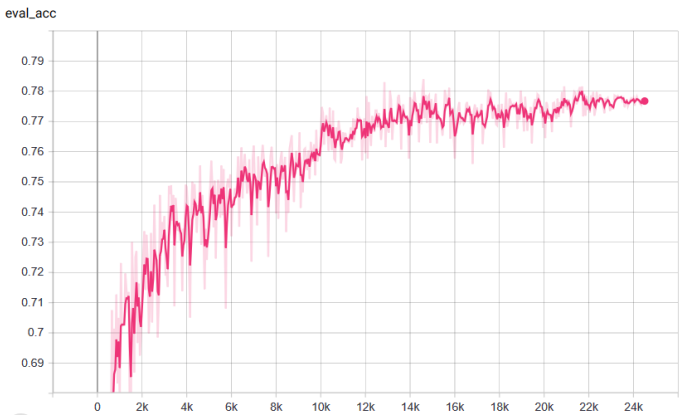

1.(c) training 過程

根據助教給的 Github Repository，先安裝好 Nvidia-Apex 等套件，再跑 `run_xnli.sh`，最後從 tensorboard 把圖片截圖下來。

2 請根據 Anisotropy 的定義以及助教提供的範例圖示，畫出 0 - 12 層各層的 Anisotropy 數值所連起來的線，每張圖片需要包含 pretrained-model 的版本跟 fine-tune 的版本，pre-trained model 的版本請用紫色線畫出來，finetune model 的版本請用綠色線畫出來

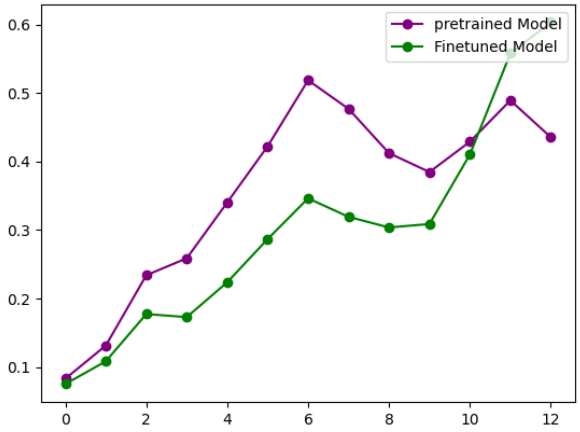

3 請根據 **self-similarity** 跟 **intra-sentence similarity** 的定義以及助教提供的範例圖示，畫出兩張圖片，一張是 **0 - 12** 層各層的 **self-similarity** 數值所連起來的線，一張是 **0 - 12** 層各層的 **intra-sentence similarity** 數值所連起來的線，每張圖片，都會有兩條線，一條線是 **pretrained model** 的版本，另一條線是 **finetune model** 的版本，**pretrained model** 的版本請用紫色線畫出來，**finetune model** 的版本請用綠色線畫出來

3.(a) self-similarity

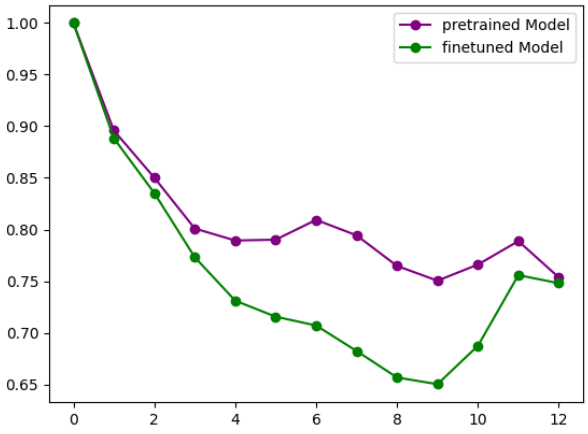

3.(b) intra-sentence similarity

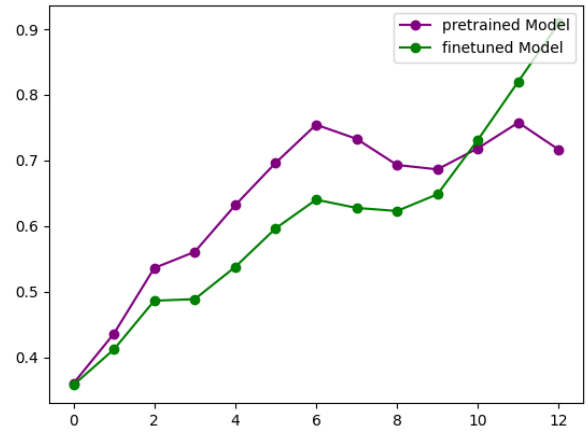

4 請把 **self-similarity** 以及 **intra-sentence similarity** 有減去各層的 **anisotropy** 的圖 **(adjust version)** 畫在本題 **(**配色如同第 **2** 題並標示清楚**)**，並且比較一下兩張圖和前一題做出來的兩張圖的差異，試著解釋一下 **finetune** 前後的變化

4.(a) self-similarity 減去 **anisotropy**

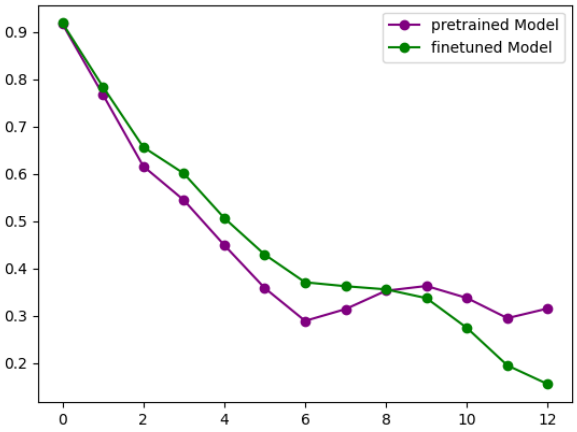

4.(b) intra-sentence similarity 減去 **anisotropy**

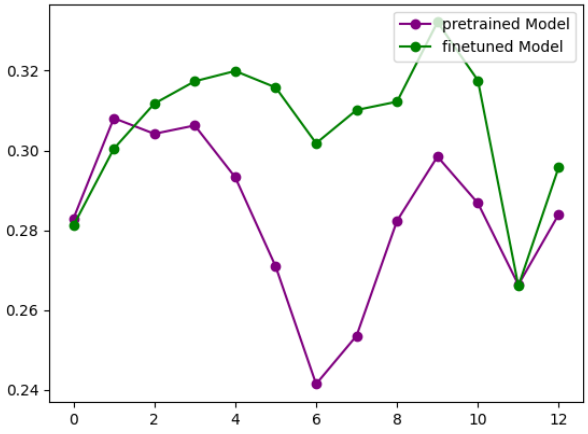

Part 2

1 Segment these sentences

(1) 我, 一直, 親自, 指揮, 、, 親自, 部署, ，, 我, 相信, 只要, 我們, 堅定, 信心, 、, 同舟共濟, 、, 科學, 防治, 、, 精準, 施策, ，, 我們, 一定, 會, 戰勝, 這, 一, 次, 疫情, 。

(2) 這, 個, 聲明, 讓, 我, 再次, 想起, 了, 安徒生, 的, 童話, 《, 皇帝, 的, 新裝, 》, 。

(3) 希望, 他們, 能夠, 聽, 一, 聽, 這, 個, 忠告, ，, 不, 要, 再, 信口雌黃, 地, 抹黑, ，, 居心叵測, 地, 挑撥, ，, 煞有介事, 地, 恫嚇, 。

(4) 有關, 部門, 當然, 就, 是, 有關, 的, 部門, 了, 。, 無關, 的, 就, 不, 能, 稱爲, 有關, 部門, 。, 所以, 我, 建議, 你, 還是, 要, 向, 他們, 詢問, 。

(5) 不, 要, 搞, 奇奇怪怪, 的, 建築, 。

(6) 現在, 提請, 表決, 。, 同意, 的, 代表, 請, 舉手, 。, 請, 放下, ；, 不, 同意, 的, 請, 舉手, 。, 沒有, ；, 棄權, 的, 請, 舉手, 。, 沒有, 。, 通過, !

(7) 人均, 國內, 生產, 總值, 接近, 八千萬, 美元, 。

(8) 我, 青年, 時代, 就, 對, 法國, 文化, 抱有, 濃厚, 興趣, ，, 法國, 的, 歷史, 、, 哲學, 、, 文學, 、, 藝術, 深深, 吸引, 著, 我, 。, 讀, 法國, 近現代史, 特別是, 法國, 大, 革命史, 的, 書籍, ，, 讓, 我, 豐富, 了, 對, 人類, 社會, 政治, 演進, 規律, 的, 思考, 。, 讀, 孟德斯鳩, 、, 伏爾泰, 、, 盧梭, 、, 狄德羅, 、, 聖西門, 、, 傅立葉, 、, 薩特, 等, 人, 的, 著作, ，, 讓, 我, 加深, 了, 對, 思想, 進步, 對, 人類, 社會, 進步, 作用, 的, 認識, 。, 讀, 蒙田, 、, 拉封丹, 、, 莫里哀, 、, 司湯達, 、, 巴爾扎克, 、, 雨果, 、, 大, 仲馬, 、, 喬治·桑, 、, 福樓拜, 、, 小, 仲馬, 、, 莫泊桑, 、, 羅曼·羅蘭, 等, 人, 的, 著作, ，, 讓, 我, 增加, 了, 對, 人類, 生活, 中, 悲歡離合, 的, 感觸, 。, 冉阿讓, 、, 卡西莫多, 、, 羊脂球, 等, 藝術, 形象, 至今, 仍, 栩栩如生, 地, 存在, 於, 我, 的, 腦海, 之中, 。, 欣賞, 米勒, 、, 馬奈, 、, 德加, 、, 塞尚, 、, 莫內, 、, 羅丹, 等, 人, 的, 藝術, 作品, ，, 以及, 趙無極, 中, 西, 合璧, 的, 畫作, ，, 讓, 我, 提升, 了, 自己, 的, 藝術, 鑑賞, 能力, 。, 還有, ，, 讀, 凡爾納, 的, 科幻, 小說, ，, 讓, 我, 的, 頭腦, 充滿, 了, 無盡, 的, 想像, 。

(9) 輕關, 易道, ，, 通商, 寬衣, 。

(10) 因爲, 我, 那, 時候, ，, 扛, 兩百, 斤, 麥子, ，, 十, 里, 山路, 不, 換肩, 的, 。

2 從助教給的例子中，我們會發現機器遇到標點符號時必定預測其 label 爲 S。如果去除標點符號，是否會對句子的 segmentation 造成影響呢？請對上述 10 句的無標點符號版本進行 segmentation，並敘述你的觀察。

(1) 我, 一直, 親自, 指揮, 親自, 部署, 我, 相信, 只要, 我們, 堅定, 信心, 同舟共濟, 科學, 防治, 精準, 施策, 我們, 一定, 會, 戰勝, 這, 一, 次, 疫情

(2) 這, 個, 聲明, 讓, 我, 再次, 想起, 了, 安徒生, 的, 童話, 皇帝, 的, 新裝

(3) 希望, 他們, 能夠, 聽, 一, 聽, 這, 個, 忠告, 不, 要, 再, 信口雌黃, 地, 抹黑, 居心叵測, 地, 挑撥, 煞有介事, 地, 恫嚇

(4) 有關, 部門, 當然, 就, 是, 有關, 的, 部門, 了, 無關, 的, 就, 不, 能, 稱爲, 有關, 部門, 所以, 我, 建議, 你, 還是, 要, 向, 他們, 詢問

(5) 不, 要, 搞, 奇奇怪怪, 的, 建築

(6) 現在, 提請, 表決, 同意, 的, 代表, 請, 舉手, 請, 放下, 不, 同意, 的, 請, 舉手, 沒有, 棄權, 的, 請, 舉手, 沒有, 通過

(7) 人均, 國內, 生產, 總值, 接近, 八千萬, 美元

(8) 我, 青年, 時代, 就, 對, 法國, 文化, 抱有, 濃厚, 興趣, 法國, 的, 歷史, 哲學, 文學, 藝術, 深深, 吸引, 著, 我, 讀, 法國, 近現代史, 特別是, 法國, 大, 革命史, 的, 書籍, 讓, 我, 豐富, 了, 對, 人類, 社會, 政治, 演進, 規律, 的, 思考, 讀, 孟德斯鳩, 伏爾泰盧梭, 狄德羅, 聖西門, 傅立葉薩特, 等, 人, 的, 著作, 讓, 我, 加深, 了, 對, 思想, 進步, 對, 人類, 社會, 進步, 作用, 的, 認識, 讀, 蒙田拉封丹, 莫里哀司, 湯達巴爾扎克, 雨果, 大, 仲馬, 喬治桑福樓拜, 小, 仲馬, 莫泊桑, 羅曼羅蘭, 等, 人, 的, 著作, 讓, 我, 增加, 了, 對, 人類, 生活, 中, 悲歡離合, 的, 感觸, 冉阿讓卡西莫多, 羊脂球, 等, 藝術, 形象, 至今, 仍, 栩栩如生, 地, 存在, 於, 我, 的, 腦海, 之中, 欣賞, 米勒馬奈德加塞尚莫內羅丹, 等, 人, 的, 藝術, 作品, 以及, 趙無極, 中西合璧, 的, 畫作, 讓, 我, 提升, 了, 自己, 的, 藝術, 鑑賞, 能力, 還有, 讀, 凡爾納, 的, 科幻, 小說, 讓, 我, 的, 頭腦, 充滿, 了, 無盡, 的, 想像

(9) 輕, 關, 易道, 通商, 寬衣

(10) 因爲, 我, 那, 時候, 扛, 兩百, 斤, 麥子, 十, 里, 山路, 不, 換肩, 的

2.(a) 我的觀察

如果去除標點符號，是會對句子的 segmentation 造成影響的。上述 10 句中，(8) 和 (9) 的 segmentation 就不一樣，除此之外都相同。

其中 (8) 有許多人名，例如「伏爾泰盧梭」或是「傅立葉薩特」等等，在沒有標點符號時會被接在一起，但其實是兩個人名。我想可能是因爲這些人名的翻譯在訓練的語料庫中沒有很常出現，所以不會被斷得很好。

另外，(9) 的「輕關」在沒有標點符號時會被斷開，我想可能是因爲語料庫中大多是現代的中文，因此在古文方面的斷詞會不穩定。